真理在辩论中变得更加清晰！具有大型语言模型的多代理系统揭开假新闻的面纱

Yuhan Liu 中国人民大学高岭学院，中国北京
y uhan.liu@ruc.edu.cn

刘宇轩 中国人民大学人工智能学院 北京，中国

张晓庆 中国人民大学人工智能学院 北京，中国

陈秀英*阿联酋阿布扎比穆罕默德-本-扎耶德人工智能大学

严蕊{v1} 中国人民大学高岭学院 中国北京 武汉大学 中国武汉

arXiv:2505.08532v1 [cs.SI] 13 May 2025

摘要

在当今的数字环境中，假新闻通过社交网络的快速传播带来了巨大的社会挑战。大多数假新闻检测方法要么采用传统的分类模型，存在可解释性低、生成能力有限等问题；要么为大型语言模型（LLM）设计特定的提示，让其直接生成解释和结果，无法充分发挥 LLM 的推理能力。受 "真理越辩越明 "这句话的启发，我们的研究引入了一种名为 TruEDebate（TED）的新型多智能体系统，以提高假新闻检测的可解释性和有效性。TED 采用了一种严格的辩论程序，其灵感来自正式辩论环境。我们方法的核心是两个创新组件：DebateFlow Agents（辩论流代理）和InsightFlow Agents（洞察流代理）。DebateFlow 代理将代理分为两队，一队支持新闻真实性，另一队质疑新闻真实性。这些代理进行开场陈述、交叉质证、反驳和总结陈述，模拟类似于人类话语分析的严格辩论过程，从而对新闻内容进行全面评估。同时，InsightFlow 代理由两个专门的子代理组成：合成代理和分析代理。综合代理对辩论进行总结，并提供总体观点，确保评估的连贯性和全面性。分析代理包括角色感知编码器和辩论图，将角色嵌入和模型整合在一起。

我们在 ARG-EN 和 ARG-CN 两个数据集上进行了大量实验，结果表明 TED 框架在各种指标上都超越了传统方法，更重要的是，它增强了可解释的假新闻的能力。我们在两个数据集（ARG-EN 和 ARG-CN）上进行的大量实验表明，TED 框架在各种指标上都超越了传统方法，更重要的是，它通过揭示逻辑推理和结构化辩论过程，提高了可解释的假新闻检测能力，从而得出准确的结论。我们发布了我们的代码，以支持在负责任的信息系统中使用结构化辩论来改进决策的信息系统[1]。

中央监控系统概念

• 计算方法 → 自然语言处理；• 安全和隐私 → 安全和隐私的人类和社会方面。

关键词

假新闻、辩论、大型语言模型、多代理系统

ACM 参考格式：

Yuhan Liu, Yuxuan Liu, Xiaoqing Zhang, Xiuying Chen, and Rui Yan.2025.真相在辩论中变得更加清晰！具有大型语言模型的多代理系统揭开假新闻的面纱。InProceedings of the 48th Inter- national ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR '25), July 13-18, 2025, Padua, Italy.ACM, New York, NY, USA, 11 pages. https://doi.org/10.1145/3726302.3730092

1 引言

通过社交网络迅速传播的假新闻已变得无孔不入，对个人、弱势社区和社会产生了重大影响。这种广泛传播给舆论治理带来了巨大挑战 [1]，影响选举 [11]，破坏公共卫生政策 [13]，损害公平 [57-59]，威胁社会稳定 [40]。

*通讯作者：

允许为个人或课堂用途免费复制本作品的全部或部分内容的电子版或印刷版，但不得以营利或商业利益为目的制作或传播，且复制件的首页须注明本声明和完整的引文。必须尊重作者以外的其他人对本作品组成部分所拥有的版权。允许摘录并注明出处。如需复制、再版、发布到服务器上或重新发布到列表中，需事先获得特别许可和/或付费。请向 permissions@acm.org 申请许可。SIGIR '25, Padua, Italy © 2025 版权归所有者/作者所有。出版权归 ACM 所有。ACM ISBN 979-8-4007-1592-1/2025/07
https://doi.org/10.1145/3726302.3730092

[1]https://github.com/LiuYuHan31/TED_ 假新闻删除

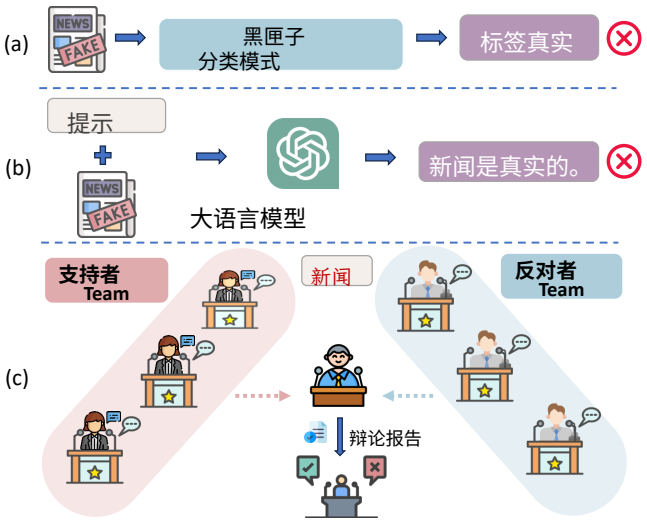


图 1：（a）传统模型主要依靠黑盒分类模型来检测假新闻。(b) LLM 直接输出检测结果，没有充分利用大型模型推理的潜力。(c) 我们的多代理框架模拟正式辩论场景，参与新闻话题讨论，通过辩论推理和可解释性得出检测结果。

传统的假新闻检测方法主要依赖于机器学习模型，尤其是那些基于 BERT [7], 的模型，它们擅长文本分析 [16, 19, 31]。虽然这些模型取得了不俗的成绩，但它们往往存在可解释性低和泛化能力有限的问题，妨碍了它们在不同环境下的有效性。最近的方法试图通过开发特定的提示来生成解释和检测结果，从而利用 LLM [15, 29]。然而，这些方法可能无法充分利用 LLMs 固有的推理能力和复杂的认知过程，经常导致结论过于简化和不成熟。

在寻求真理的过程中，谚语 "真理在辩论中变得更加清晰 "强调了从多角度审视和质疑信息以获得更准确理解的重要性 [2, 21]。在有条理的辩论中交流不同观点往往能完善和澄清观点。然而，现有的假新闻检测模型未能充分结合这一方法，往往将其分析局限于单一的、不受质疑的观点。这种限制妨碍了对新闻内容的全面评估，并可能忽略对准确检测至关重要的细节信号。

为了应对这些挑战，我们引入了一种名为 TruEDebate（TED）的新型多智能体系统。TED 旨在通过采用正式辩论的结构化方法来提高假新闻检测的可解释性和有效性。受 "真理在辩论中更清晰地显现 "这一原则的启发，我们的方法模拟了多个代理之间的动态结构化辩论，每个代理都从不同角度审视新闻。这种辩论结构遵循林肯-道格拉斯辩论（Lincoln-Douglas Debate [8], 的形式，代理参与一系列阶段，提出、质疑和完善他们的论点。这一框架反映了人类通过 "反驳 "来评估信息的认知过程，促进了深度智力参与和对新闻内容的全面评估。在这一框架中，多个代理（每个代理都被分配了不同的角色）参与结构化的辩论过程，以评估新闻条目的真实性。这一辩论过程加强了对检测过程的解释，并反映了人类的辩论认知过程，即对相互冲突的观点进行分析和整合。

TED 框架包括两个创新组件：DebateFlow 代理和 InsightFlow 代理。DebateFlow 代理将多个由 LLM 驱动的代理组织成两个对立团队，一个支持新闻真相，另一个反对新闻真相。这些代理依次进行开场陈述、交叉质证反驳和总结陈词，有效地模拟了严格的辩论环境。这种设置鼓励对不同观点的探索、完善和澄清，并解决了现有模型从单一角度分析信息的局限性。同时，InsightFlow 代理包括两个专门的子代理：综合代理和分析代理。综合代理负责总结辩论内容，提供全面的观点，确保得出连贯、透彻的结论。分析代理由角色感知编码器和辩论图组成，通过互动关注机制整合角色嵌入，并模拟不同辩论角色和论点之间的互动。通过捕捉辩论中的详细关系和内在话语结构，分析代理能有效识别假新闻检测所必需的关键指标。

我们在 ARG- EN 和 ARG-CN 两个数据集上进行了综合实验，以评估 TED 的有效性。结果表明，我们的框架在多个评价指标上都优于传统方法。此外，TED 还促进了结构化辩论程序，增强了逻辑推理能力，有助于得出准确的结论。通过系统化的辩论和深入分析，我们的方法推动了信息系统的发展，使决策过程更加精确和透明，从而支持创建负责任的信息环境。

我们的贡献可以概括为以下几个方面：

- 我们介绍了基于 LLM 的新型可解释假新闻检测框架 TED。TED 不仅能通过结构化辩论进行检测，还能提供可解释的理由，帮助理解检测结果。

{林肯-道格拉斯辩论理论• 认为 "真理在辩论中变得更加清晰"，受该理论的启发，我们在框架中设计了两个关键组件：合成代理和分析代理。综合代理总结辩论内容，综合全面的观点，确保得出连贯的结论。分析代理集成了角色感知编码器和辩论图，整合了角色嵌入，并通过关注机制模拟不同辩论角色和论点之间的相互影响。这种结构使分析代理能够识别对准确识别假新闻至关重要的关键指标。

•在ARG-EN和ARG-CN数据集上进行的大量实验表明，TED的性能优于传统方法，显示了其做出准确透明决策的能力。此外，TED 还能在不同的 LLM 主干网中保持稳定的性能，展示了它在假新闻检测方面的适应性和通用性。

2 相关工作

2.1 假新闻检测

假新闻检测是打击误报的重要一步 [12]。该领域的早期研究包括 Qian 等人的研究 [36], ，该研究侧重于假新闻的早期检测，只涉及检测时可用的新闻文章文本。Yu等人 [49] 采用卷积方法进行错误信息识别。随着该领域的发展，人们引入了各种方法来提高检测效率。例如，Jin 等人 [17] 通过更好地反映人类思维的逻辑过程和实现对微妙线索的建模，向细粒度推理假新闻检测迈进。此外，Zheng 等人 [60] 考虑到多模态数据相互关系的复杂性，研究了如何整合这些数据。最近，随着大型语言模型的兴起，Hu 等人 [15] 将大型和小型语言模型结合起来，仅使用文本内容进行假新闻检测就取得了很好的改进。Li 等人 [25] 设计的基于大型语言模型的代理工作流利用工具学习和知识检索来检测假新闻。Liu等人 [27, 28] 采用多代理系统模拟假新闻的传播和演变。

然而，他们并没有充分利用 LLMs 的潜力。我们的研究通过进一步利用由多个具有 LLMs 的代理组成的辩论系统，增强了假新闻检测的能力。在我们的方法中，我们不需要调用任何外部工具，也不需要基于知识的检索，因此很容易移植到任何假新闻检测场景中。

2.2 有LLM 的多代理讨论

尽管LLM取得了长足进步，但关于多个LLM互动协作解决问题的多代理讨论的研究仍处于早期阶段，其目标是利用超越单个模型的集体能力。ChatEval [3], 是这一领域的一个重要贡献，它设计了一个多代理裁判团队，以独立审议和评估各种模型对开放式问题和标准自然语言生成任务所生成的回答的质量。其他研究则强调代理人角色的多样化，以丰富辩论过程 [24, 33]。Liang 等人 [26] 进一步探讨了角色分配如何影响多代理互动的效率。Chen等人 [4] 提出了ReConcile框架，该框架使用不同的LLM和加权投票系统来达成共识，从而捕捉到更广泛的观点。Du 等人 [9] 利用多代理辩论来提高 LLM 的数学能力。此外，Zhang 等人 [52]从社会心理学角度分析了多代理讨论，以了解社会因素如何影响代理之间的协作和推理过程。

然而，这些作品并没有在其框架内真正描绘辩论过程，也无法从多个角度分析问题。在这些基础上，我们的工作引入了一个结构化辩论框架，利用多代理交互来提高假新闻检测的可解释性和有效性。

2.3 基于 LLM 的多代理系统

凭借 LLMs 强大的文本生成能力，将 LLMs 集成到社会动态模拟中是一个新兴的研究领域，并取得了可喜的成果 [18, 23, 39, 45]。这些基于 LLM 的生成代理在数字环境中表现出色，能够熟练完成自然语言任务 [5, 6, 50] 和推理任务 [51]。Törnberg等人 [42]利用LLM和基于代理的建模来模拟社交媒体，重点研究新闻源算法，并提出了对现实世界的见解。此外，Park 等人 [34] 证明了基于 LLM 的代理可以生成与人类生成的内容不同的社交媒体内容。此外，Qian 等人 [35]设计了一个模拟人类开发团队的虚拟开发公司 ChatDev。

这些利用 LLM 多代理系统解决复杂任务的框架都有一个共同的重要组成部分：多个代理 [3, 14, 30, 41, 46, 54-56] 之间的交互。然而，这些著作只考虑了不同代理之间的信息传递。虽然有些著作声称可以进行多代理辩论，但它们并没有充分描述交互过程中的辩论过程。我们的工作建立了一个标准的辩论场景，不同角色从不同角度对假新闻进行辩论，以确定新闻主题的真实性。据我们所知，这是首次在假新闻背景下模拟社会辩论。

3 方法

3.1 制定任务

我们将假新闻检测重新表述为多个 LLM 代理之间的互动辩论。我们引入了一个由 NLLM 代理组成的系统，表示为 A = （a_1，……，a_N），每个代理在辩论过程中都被分配了独特的角色和立场。给定一个新闻条目 F，所有代理进行结构化辩论，以确定其真实性。代理被组织成两个对立的团队：

- 支持者：认为 F 为真的代理人。
- 反对者：认为 F 为假的代理人。

每个代理都在辩论中扮演特定的角色，并参与预定义的阶段。所有互动都记录在辩论日志 D中。在辩论结束阶段，有两类代理对结果进行评估。合成代理对辩论日志 D 进行分析，以生成一份全面的总结报告 S。同时，分析代理利用总结报告 S 和原始新闻 F 来预测真相值。

我们的目标是在这一辩论框架内利用 LLM 的推理能力，提高假新闻检测的有效性和可解释性。

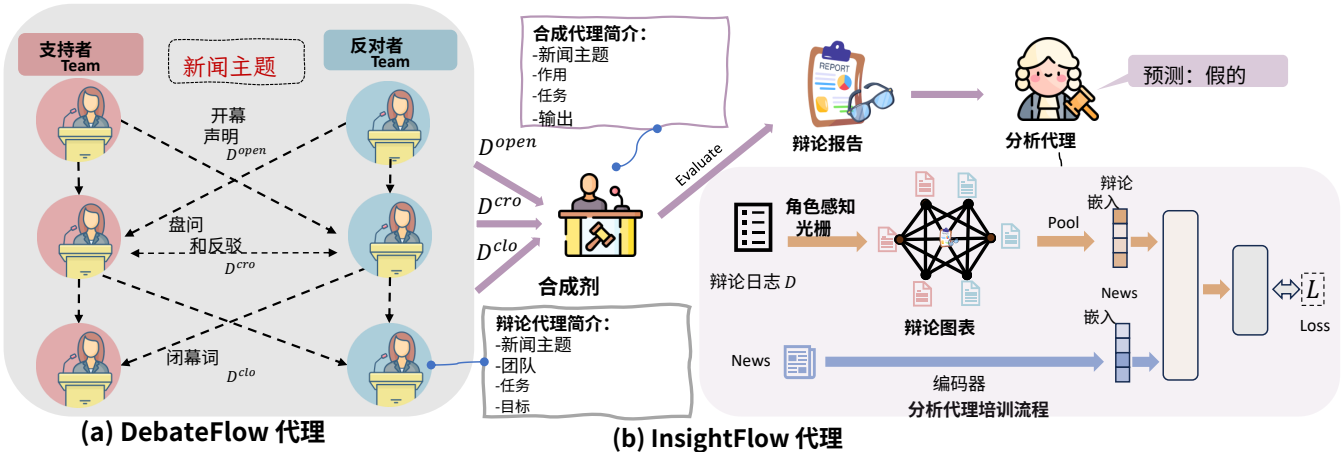


图 2：我们的 TED 框架由两个主要部分组成：(a) DebateFlow 代理和 (b) InsightFlow 代理。DebateFlow 代理模拟辩论场景中的推理过程，包括开篇、反诘问、反驳和结案陈词。InsightFlow 代理由合成代理和分析代理组成。前者根据所有辩论记录生成辩论报告，然后传递给后者以预测新内容是否属实。

3.2 我们的多代理人辩论框架

我们介绍的 TruEDebate（TED）是一个通过模拟多个 LLM 驱动的代理之间的结构化辩论来加强假新闻检测的框架。TED 由两个主要部分组成：

•辩论流程代理：组织成两个对立的团队--正方，负责论证新闻的真实性；反方，负责论证新闻的虚假性。受林肯-道格拉斯（Lincoln-Douglas）辩论理论的启发 [8]，，这些代理参与多阶段的辩论过程，包括开场、盘问、反驳和总结陈词。这种设置反映了正式的辩论环境，鼓励从多个角度对新闻进行彻底审查。

• InsightFlow 代理：由综合代理和分析代理组成。合成代理对辩论进行总结，提供关键论点和反驳论点的连贯概述。分析代理采用角色感知编码器和辩论图来模拟辩论中的互动和话语结构，最终预测新闻的真实性。

如图 2 所示，通过这些代理的互动，TED 促进了深度智力参与和逻辑推理，从而实现了更准确、更可解释的假新闻检测。结构化的辩论过程不仅完善了代理对新闻事件的理解，还为最终决定提供了透明的理由，体现了 "真理越辩越明 "的原则。

3.3 DebateFlow 代理

DebateFlow代理构成了TED框架的核心，负责组织结构化辩论，以评估新闻 F的真实性。代理被分为两个对立团队：正方（Tpro）和反方（Topp），正方认为 F是真的，反方则认为 F是假的。每个团队都由代理人组成，他们被分配了与不同辩论阶段相对应的特定角色。

受林肯-杜格拉斯辩论 [8], 的启发，辩论分为三个主要阶段：开篇、盘问和反驳以及结尾。让 $\Phi = \{\phi_1, \phi_2, \phi_3\}$ 表示这些阶段。在每个阶段 $\phi_k \in \Phi$ 中，两队的代理人根据各自的角色参与。在开场阶段（ϕ_1），代理人提出支持本队立场的初始论据。每个代理人 a_i 根据新闻 F和本队立场生成一个论据 $d(1)_i$：

$$d_i^{(1)} = f_{arg}(F, Stance_i), \quad (1)$$

其中，f_{arg} 代表由 LLM 执行的论证提示功能，$Stance_i \in \{True, Fake\}$对应于团队的立场。

在交叉询问和反驳阶段（ϕ_2），代理人通过提问和反驳来质疑对方的论点。一队的代理人a_j 针对对方在前一阶段提出的论点提出问题或反驳$d(2)_j$：

$$d_j^{(2)} = f_{reb}(D^{(1)}, Stance_j), \quad (2)$$

其中，f_{reb} 是反诘问和反驳提示函数，$D(1)$ 是阶段 ϕ_1 的参数集。

在结束阶段（ϕ_3），代理人总结自己团队的立场并强化关键点。每个代理人 a_k 都要做总结发言 $d(3)_k$：

$$d_k^{(3)} = f_{clo}(D^{(1)} \cup D^{(2)}, Stance_k), \quad (3)$$

其中，f_{clo}是收尾提示函数，$D(1) \cup D(2)$代表前几个阶段累积的辩论内容。

辩论日志 D 累积了辩论期间的所有互动：

$$D = \bigcup_{k=1}^{3} D^{(k)}, \quad \text{with} \quad D^{(k)} = \{d_i^{(k)} \mid a_i \in \mathcal{A}^{(k)}\}, \quad (4)$$

1: 输入新闻条目 F2： 输出：预测新闻 F的真相值$\hat{y}$，解释性理由 R3： 初始化 DebateFlow 代理：4: 将代理分成两队：

- 组成部分：支持 F 为真
- 反对者论证 F 是假的

5：在每个小组内分配角色（例如，开场发言人、提问者、结辩发言人） 6：辩论流程代理：7：对于每个辩论阶段 ϕ，在 [开篇陈词、交叉质询、反驳和结辩]中进行 8：代理 i 根据角色提出论点或反驳 9：在辩论日志 D_ϕ中记录互动 10：结束 11：InsightFlow 代理：12：合成代理： 13：分析辩论日志 $D = \{D_\phi\}$，生成评估报告 S14：分析代理： 15：对于 D 中的每个辩论互动（节点） n_i，执行 16：使用角色感知编码器获取节点 n_i 嵌入 h_i 17：结束 for 18：使用节点 $V = \{h_i$构建 Dabate 图 $G = （V, E）$ $G = (V, E)$19：对 G 应用 GAT，获得图嵌入 g20：对新闻条目 F 编码，获得内容嵌入 e_F21：组合表示 $c \leftarrow \text{InteractiveAttention}(g, e_F)$ 22：使用 c预测真值$\hat{y}$ 23：返回预测真值$\hat{y}$，解释原因$R = \{S, D\}$

算法 1：TruEDebate (TED)：多代理辩论框架--假新闻检测工作

其中 A (k) 是参与阶段 ϕ_k 的代理人集合。

每个代理人的贡献 d（k）$_i$取决于新闻项目 F、其团队的立场、其在辩论中的角色以及之前的辩论背景$D^{<k}$：

$$d_i^{(k)} = f_{\text{LLM}}(F, D^{<k}, \text{Role}_i, \text{Stance}_i), \tag{5}$$

其中， $D^{<k} = \bigcup_{m=1}^{k-1} D(m)$ 表示截至阶段 ϕ_{k-1} 的辩论历史，而角色$_i$则指定了代理的角色。

整个算法过程可在算法 1 中描述。这种结构化的互动确保了代理同时考虑新闻内容和不断变化的辩论背景，促进了推理的连贯性和深度。通过参与这一过程，DebateFlow 代理模拟了对新闻项目 F 的严格审查，反映了人类辩论的动态，并促进了从多个角度进行综合评估。

整套功能提示可在我们的代码文件中找到。

3.4 InsightFlow 代理

在辩论流代理进行辩论之后，洞察流代理对积累的话语进行分析，对新闻 F的真实性做出最终预测。该部分由两个主要代理组成：合成代理和分析代理。

3.4.1 综合代理。合成代理处理辩论日志 D（其中包含辩论阶段的所有互动），生成一份简明而全面的摘要 S，总结双方提出的关键论点和反驳意见。该摘要将从假新闻检测的多个角度进行评估，以确保做出全面的判断。形式上，合成代理的核心功能提示定义如下：

> 报告应详细说明您对辩论的评估。通过检查以下内容，重点评估该话题所涉及新闻的真实性：1.新闻是否包含具体细节和可核实信息。2.新闻是否引用了可靠的消息来源或新闻组织。3.新闻的语气和风格，真实的新闻通常更加客观和中立。4.是否使用情绪化语言，这可能是假新闻的特征。5.新闻中的信息是否可以通过其他可靠渠道得到证实。

综合代理的目的是概括辩论的关键要点，提供一个连贯的概述，突出双方论点的优缺点。这个综述 S 连接了辩论话语和后续分析流程，确保最相关的信息随时可供进一步评估。

3.4.2 分析代理。分析代理将辩论互动与原始新闻内容相结合，以预测新闻条目 F的真值$\hat{y}$。该代理结合使用了角色感知编码器、辩论图和新闻-辩论互动关注机制，以捕捉辩论的语义内容和关系动态，以及它们与新闻内容的相关性。

角色感知编码器。为了捕捉不同辩论角色的显著特征，我们设计了一种角色感知编码器。对于每个辩论互动 d_i，节点表示是通过将编码器的 [CLS]令牌嵌入与预测的角色嵌入相结合来构建的：

$$\begin{aligned} \mathbf{h}_i^{\text{enc}} &= \text{Encoder}(\text{Text}_i), \\ \mathbf{r}_i^{\text{proj}} &= \mathbf{W}_{\text{role}}\, \mathbf{e}_i, \\ \mathbf{h}_i^{\text{node}} &= \left[\mathbf{h}_i^{\text{enc}} ; \mathbf{r}_i^{\text{proj}} \right], \end{aligned} \tag{6}$$

其中，henc$_i$ $\in \mathbb{R}^{d_h}$ 是来自编码器的 [CLS]令牌表示，e$_i$ $\in \mathbb{R}^{d_r}$ 是角色 r_i的嵌入，Wrole $\in \mathbb{R}^{d_h \times d_r}$投射角色嵌入以匹配编码器的维度， [;] 表示向量连接。由此产生的节点代表 hnode$_i$ 整合了每次辩论互动的语义内容和特定角色信息。

辩论图。编码后的节点表示被构造成一个辩论图 $G = (V, E)$，其中节点 $V = \{h\text{node}_i\}$ 为 $G = (V, E)$。

代表辩论互动，边 E 代表互动之间的关系，如顺序或明确引用。

我们采用图注意网络（GAT）[43] 来处理节点表征。GAT 层通过关注每个节点的邻居来更新每个节点的表征：

$$\mathbf{h}_i^{(l+1)} = \sigma\left(\sum_{j\in\mathcal{N}(i)} \alpha_{ij}^{(l)}\mathbf{W}^{(l)}\mathbf{h}_j^{(l)}\right), \tag{7}$$

其中，$\mathrm{h}(l)_i$ 是节点 i 在层 l 中的表示，$\mathrm{N}(i)$ 表示节点 i 的邻居集，$\mathrm{W}(l)$ 是可学习的权重矩阵，σ 是激活函数，$\alpha(l)_{ij}$ 是注意力系数。通过堆叠多个 GAT 层，该模型可以捕捉辩论中的高阶交互和关系动态。

辩论-新闻互动关注。为了将辩论表征与新闻内容结合起来，我们采用了一种互动关注机制。首先，我们对新闻内容 F 进行编码，然后应用全局池化，得到图层面的辩论表征 g：

$$\begin{aligned} \mathbf{e}_F &= \mathrm{Encoder}(F), \\ \mathbf{g} &= \mathrm{GlobalPool}(\mathbf{H}^{(L)}), \end{aligned} \tag{8}$$

其中，$\mathrm{H}(L)$ 是第 L 个 GAT 层的输出，GlobalPool 表示全局均值池操作。

接下来，我们将辩论表征和新闻内容嵌入投影到一个共同的维度上：

$$\begin{aligned} \mathbf{g}^{\mathrm{proj}} &= \mathbf{W}_g\mathbf{g}, \\ \mathbf{e}_F^{\mathrm{proj}} &= \mathbf{W}_e\mathbf{e}_F, \end{aligned} \tag{9}$$

其中 $\mathrm{W}g$ 和 $\mathrm{W}e$ 是投影矩阵。

然后，我们利用多头注意力（MHA）计算出互动表示 c，以捕捉脱口秀和新闻内容之间的互动：

$$\mathbf{c} = \mathrm{MHA}(\mathbf{e}_F^{\mathrm{proj}}, \mathbf{g}^{\mathrm{proj}}, \mathbf{g}^{\mathrm{proj}}), \tag{10}$$

最后，我们将预测辩论表示法与互动表示法合并，得到综合表示法：

$$\mathbf{h} = [\mathbf{g}^{\mathrm{proj}}; \mathbf{c}]. \tag{11}$$

这种互动式关注使模型能够关注与新闻内容相关的辩论的不同方面，有效地整合来自两个来源的信息。

代理训练。组合表征 h 通过全连接层处理，然后通过软最大激活生成类别的预测概率分布。模型的训练方法是尽量减少预测概率与实际标签之间的交叉熵损失：

$$\begin{aligned} \hat{\mathbf{y}} &= \mathrm{softmax}(\mathbf{W}_{\mathrm{fc}}\mathbf{h} + \mathbf{b}_{\mathrm{fc}}), \\ \mathcal{L} &= -\sum_k y_k \log \hat{y}_k, \end{aligned} \tag{12}$$

其中，Wfc 和 bfc 表示分类层的权重和偏置，ˆy 表示预测概率分布，y_k 是类别 k 的基本真实标签，$\hat{y}_k$ 是类别 k 的预测概率。

4 实验

4.1 实验设置

4.1.1 数据集为了进行评估，我们使用了两个数据集：ARG-EN 和 ARG-CN [15]。这两个数据集分别来自中文数据集微博 21 [32] 和英文数据集 GossipCop [38]。在之前的工作 [15], 中，他们通过重复数据删除和时间分割来处理这些数据集。这种方法有助于防止因潜在的数据泄漏而高估 SLM 性能。我们在实验中使用了这两个数据集。表 2 总结了数据集的统计详情。

4.1.2 基线根据之前的工作 [15], , 我们对三种方法进行了实验比较。

- 仅 LLM 方法：直接使用 GPT-3.5-turbo 和 GPT-4o- mini 作为假新闻检测的 LLM。
- 纯小语言模型（SLM）方法：小语言模型（SLM）与基于 BERT 的模型一样，通常在假新闻检测任务中表现良好。在这一类别中，我们包括以下方法：

(1) Bert [7]：使用经过微调的 vanilla BERT-base 模型检测假新闻。

(2) EANN [44]：该模型采用辅助对抗训练法，以发表年份作为辅助任务的标签，有效地分离和减少与事件相关的特征。

(3) Publisher-Emo [53]：该模型整合了一系列情感属性和文本特征，用于检测假新闻。

(4) ENDEFA [61]：该模型利用因果学习来消除实体偏差，从而增强了其在假新闻数据集上的泛化能力。该类别中的所有方法都使用相同的 SLM（BERT）进行文本编码。

- LLM+SLM 方法。单纯的 LLM 通常在任务中表现不佳。因此，许多研究将 LLM 与 SLM 结合起来，以提高性能。

(1) Bert+理由：它结合了新闻和理由编码器的特征，将其输入 MLP 进行预测。

(2) SuperICL [47]：它利用 SLM 作为插件，通过将每个测试样本的预测和置信度纳入提示，增强 LLM 的情境学习能力。

(3) ARG [15]：该模型为假新闻检测设计了一个自适应理由指导网络，其中 SLM 从 LLM 提供的理由中选择性地获得新闻分析的见解。

(4) ARG-D [15]：它是通过蒸馏创建的 ARG 的无理版本，设计用于不需要查询 LLM 的成本敏感型场景。

4.1.3 实现细节。我们使用 Python 来实现我们的框架 TED。使用的 LLM 是通过 OpenAI API 调用访问的 GPT-4o-mini，这是因为它具有代表性且调用方便。我们使用 Python 库 Mesa [20] 定义了代理和它们所处的场景。对于分析代理，我们使用了微调 BERT 模型，因为最近的研究 [19]强调了该模型在这一领域的广泛应用。在实验中，我们使用了 Transformers 软件包中的中文-bert-wwm-ext 模型和 bert-base-uncased 模型进行英文评估。我们使用 Adam [22]，通过全面的网格搜索进行优化，以达到最佳效果。

表 1：对 TED 以及纯 LLM、纯 SLM 和 LLM+SLM 方法的性能进行了评估。基线的所有结果（GPT-4o-mini 和 ChatEval 的结果除外）均来自 Hu 等人的研究 [15]。macF1-分数和准确率的前两项结果均突出显示，每个类别中最高的结果用粗体表示，第二高的结果用下划线表示。粗体数字表示基线模型的改进具有统计学意义（t 检验，p 值<0.01）。

模型		ARG-EN				ARG-CN			
		macF1	Acc.	$F1_{真实}$	$F1_{伪造}$	macF1	Acc.	$F1_{真实}$	$F1_{伪造}$
仅限法学硕士	GPT-3.5-turbo	0.702	0.813	0.884	0.519	0.725	0.734	0.774	0.676
	GPT-4o-mini	0.691	0.845	0.909	0.472	0.725	0.746	0.780	0.670
仅限 SLM	Bert	0.765	0.862	0.916	0.615	0.753	0.754	0.769	0.737
	EANN	0.763	0.864	0.918	0.608	0.754	0.756	0.773	0.736
	出版商-Emo	0.766	0.868	0.920	0.611	0.761	0.763	0.784	0.738
	结束语	0.768	0.865	0.918	0.618	0.765	0.766	0.779	0.751
LLM+SLM	伯特 + 理由	0.777	0.870	0.921	0.633	0.767	0.769	0.787	0.748
	超级ICL	0.736	0.864	0.920	0.551	0.757	0.759	0.779	0.734
	ARG	0.790	0.878	0.926	0.653	0.784	0.786	0.804	0.764
	ARG-D	0.778	0.870	0.921	0.634	0.771	0.772	0.785	0.756
多方代理	聊天评估（逐个评估）	0.733	0.860	0.919	0.546	0.694	0.717	0.778	0.611
	聊天评估（同时聊天）	0.738	0.869	0.923	0.553	0.694	0.719	0.780	0.608
	特德（我们的）	**0.803**	**0.892**	**0.932**	**0.674**	**0.795**	**0.798**	**0.815**	**0.774**

表 2：假新闻检测数据集的统计数据。

	ARG-CN			ARG-EN		
	火车	**Val**	**Test**	**火车**	**Val**	**Test**
Real	2,331	1,172	1,137	2,878	1,030	1,024
Fake	2,873	779	814	1,006	244	234
总计	5,204	1,951	1,951	3,884	1,274	1,258

确定最佳学习率。使用测试结果中的最佳验证检查点来评估性能。对于分析代理，实验使用 PyTorch 进行，其中 HuggingFace Transformers 库用于预训练模型，PyTorch Geometric 用于图神经网络组件。文本数据使用适合数据集语言的 BERT 标记器进行标记。辩论互动使用角色感知嵌入编码，新闻内容使用 BERT 模型单独编码。此外，每个辩论实例都采用了固定的图结构，节点代表辩论互动，边代表这些互动之间的逻辑流和关系。边是根据辩论顺序和角色之间的互动预先定义的。所有实验都在配备英伟达 3090 GPU 的机器上运行，以加速训练。具体的实验实施细节可参见我们的代码。

4.2 主要成果

表 1 列出了我们提出的 TED 框架和其他各种模型（如纯 LLM、纯 SLM 和 LLM+SLM 方法）在 ARG-EN 和 ARG-CN 数据集上的性能。结果表明：(1) TED 优于所有其他方法，在所有数据集上都获得了最高的 macF1 分数和准确率、展示了其在检测假新闻方面的卓越能力。这凸显了我们的多代理辩论法在全面分析和判断新闻真实性方面的功效。(2) 与 TED 相比，仅使用 LLM 的方法（不使用结构化论证的 LLM）表现逊色。(3) 仅使用 SLM 的方法之间的比较显示，每种变体的性能都在逐步提高，但都没有达到 TED 的性能水平。这表明，传统的 SLM 虽然有能力，但与 TED 的多代理系统所提供的强大而全面的分析框架相比，还是有差距的。(4) LLM+SLM 方法试图结合 LLM 与 SLM 的能力，但表现各异。例如，ARG 模型显示出相当的有效性，但仍未达到 TED 的水平。这表明，虽然 LLM 和 SLM 的整合带来了好处，但 TED 的结构化辩论形式对最佳性能至关重要。

此外，为了评估 TED 框架在假新闻检测方面的有效性，我们将其与 ChatEval 框架 [3], 进行了比较，后者使用 "一对一"（One-by-One）和 "同时对话"（Simultaneous-Talk）策略进行多代理辩论。将这些策略应用于假新闻检测任务，如表 1 所示，在所有指标上，TED 始终优于 ChatEval。TED 的正式辩论结构促进了代理之间更多的互动推理，从而可以对新闻内容进行更深入的分析。相比之下，ChatEval 的策略在假新闻检测方面没有达到同样的深度。这些结果凸显了 TED 在提高多代理系统假新闻检测的准确性和可靠性方面的优势。通过融合结构化和动态的交互，TED 不仅提高了检测的准确性，还确保了对新闻项目进行更彻底的检查。

表 3：我们的模型 TED 在 ARG-EN 和 ARG-CN 数据集上的消融研究。粗体数字表示消融模型的改进具有统计学意义（t 检验，p 值 <0.01）。

	ARG-EN				ARG-CN			
	macF1	Acc.	$F1_{真实}$	$F1_{伪造}$	macF1	Acc.	$F1_{真实}$	$F1_{伪造}$
完整模型 (TED)	**0.803**	**0.892**	**0.932**	**0.674**	**0.795**	**0.798**	**0.815**	**0.774**
无 *DebateFlow* 代理	0.780	0.874	0.918	0.642	0.767	0.781	0.795	0.739
不含合成剂	0.792	0.881	0.924	0.660	0.771	0.787	0.801	0.741
不含分析剂	0.729	0.856	0.915	0.543	0.737	0.736	0.785	0.689

5 分析与讨论

5.1 消融研究

我们进行了一项消融研究，以评估 TED 框架中每个组成部分的影响。结果表明，去掉 DebateFlow 代理后，macF1 分数在 ARG-EN 和 ARG-CN 上分别降低了约 2.3% 和 2.8%。这一下降凸显了结构化辩论流程在促进多角度综合分析方面的重要性，而多角度综合分析对于准确判断新闻项目的真实性至关重要。去掉合成代理后，macF1 分数略有下降，在 ARG-EN 中下降了 1.1%，在 ARG-CN 中下降了 2.4%。这凸显了合成代理在将辩论互动整合为连贯的摘要方面的关键作用，从而提高了模型有效整合不同论点以进行精确分类的能力。省略分析代理导致的得分下降最为明显，macF1 在 ARG-EN 上的得分下降了 8.0%，在 ARG-CN 上的得分下降了 4.5%，这强调了分析代理在将辩论见解与新闻内容相结合方面的关键作用。总之，消减结果证实了 TED 框架的每个组件对于实现假新闻检测的高性能都是不可或缺的。辩论流代理（DebateFlow Agents）实现了稳健的多代理互动；合成代理（Synthesis Agent）确保了辩论结果的有效整合，而分析代理（Analysis Agent）则将这些见解与新闻内容整合在一起，以获得精确的结果。

5.2 不同骨干网的性能

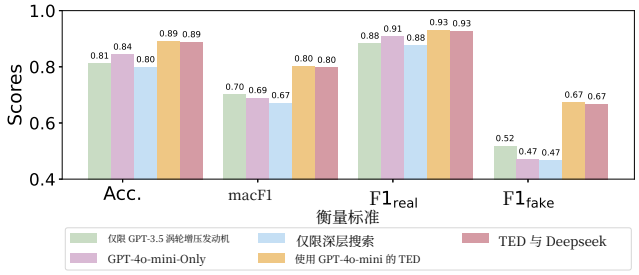


图 3：我们的框架 TED 在使用 GPT-4o- mini 和 Deepseek 作为闭源骨干网时的性能。

5.2.1 闭源模型的性能。为了评估 TED 框架的易用性和可变性，我们在 ARG-EN 数据集上进行了实验，用不同的闭源模型替换了 DebateFlow 代理和合成代理、即 GPT-4o-mini 和 Deepseek[2]。图 3 显示，在所有评估指标上，与基线 LLM-Only 模型相比，无论使用哪种闭源模型，TED 都能持续提升性能。这一结果凸显了该框架对不同大规模模型的适应性，表明 TED 有效地利用了各种闭源骨干网的独特优势。此外，我们还观察到，使用 GPT-4o-mini 的 TED 和使用 Deepseek 的 TED 性能相当，GPT-4-mini 略胜一筹。这表明，虽然这两个模型具有竞争力，但 GPT-4o-mini 似乎在某些方面略胜一筹，尤其是在处理复杂推理任务方面。尽管如此，两个骨干网的结果都强调了 TED 在提高假新闻检测性能方面的稳健性，而与所使用的特定闭源模型无关。这些发现强调了 TED 并不局限于单一的骨干网，它可以有效地提高不同闭源模型的性能。TED 在使用 GPT-4o-mini 时略胜一筹，这进一步证实了 TED 可以利用每个模型推理能力的固有优势这一观点。这种适应性确保了 TED 在实际应用中的有效性和可靠性。

总之，TED 框架被证明既有效又适应性强，在各种闭源模型中都能保持强劲的性能。这些结果验证了 TED 在各种应用场景中的实用性，使其成为一种用途广泛的假新闻检测工具。

表 4：分别以 Qwen2.5 和 Llama3.1 家族模型为骨干的 TED 性能。带下划线的数字表示使用开源模型时的最佳性能，且具有统计学意义（t 检验，p 值<0.01）。

骨架	#Param	macF1	**Acc**	$F1_{\textbf{real}}$	$F1_{\textbf{fake}}$
GPT-4o-mini	-	0.803	0.892	0.932	0.674
Qwen 2.5 [48]	7B	**0.794**	**0.887**	**0.926**	**0.661**
拉马 3.1 [10]	8B	0.787	0.879	0.920	0.653
拉马 3.1 [10]	70B	0.790	0.884	0.923	0.657

5.2.2 开源模型的性能。为了进一步评估 TED 框架的适应性和鲁棒性，我们在 ARG-EN 数据集上使用多个开源语言模型测试了其性能，包括 Qwen-2.5 [48] 和 Llama 3.1 系列 [10]。如表 4 所示，TED 持续改善了 ARG-EN 数据集的性能。

[2]https://www.deepseek.com/

在所有开源模型中，TED 的表现都很突出，这表明无论使用何种特定语言模型，它都能显著增强假新闻检测能力。这表明，TED 不受骨干模型的可用性或类型的限制，因此成为适用于各种实际应用的通用而有效的工具。一般来说，TED 在 Qwen 2.5 中的性能略微优于 Llama 3.1 变体。虽然性能差异很小，但这表明 Qwen 2.5 特别适合 TED 的辩论驱动框架。它可以更好地处理复杂的论证和上下文，这对于 TED 所依赖的结构化评估至关重要。另一方面，使用 Llama 3.1 模型的 TED 也表现出色，所有配置的结果都优于基线方法，进一步验证了 TED 在不同模型中的有效性。虽然开源模型的性能低于 GPT-4o-mini 的结果，但这可能是由于这些模型的底层推理能力不同造成的。开源模型虽然能力很强，但在细微推理方面可能不如 GPT-4o-mini 等封闭源模型。尽管如此，即使使用这些开源骨干，TED 仍能继续产生强大的结果，这表明它仍然可以利用每个模型的优势来实现高水平的准确性和可靠检测。

总体而言，结果凸显了 TED 的稳健性和多功能性。它不断提高假新闻检测性能。这些研究结果表明，TED 非常适合在各种环境中部署，包括对特定模型的访问可能有限或首选开源模型的情况。

5.3 案例研究

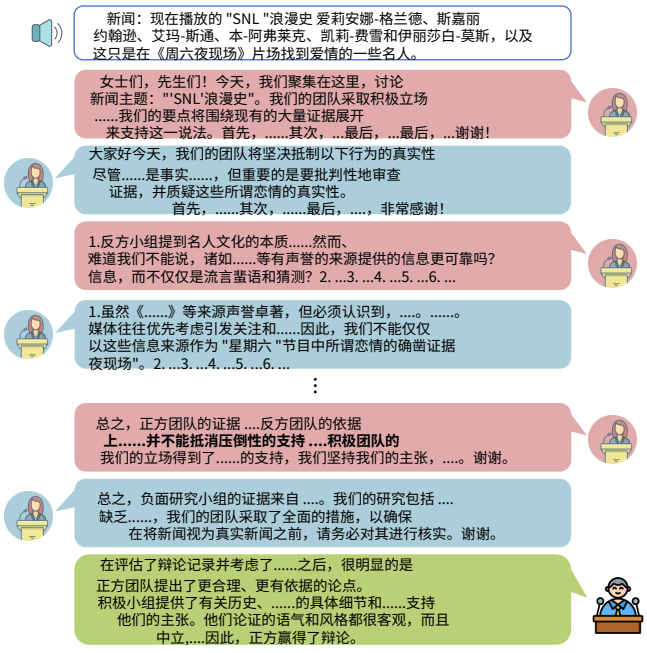


图 4：区域辩论案例研究及其辩论报告可作为可解释假新闻检测的依据。

图 4 展示了以假新闻为案例的辩论过程的微观比较分析。在这场辩论中，参赛者分为正方和反方两队，通过开篇、盘问和总结陈词完成辩论情景。辩论开始时，正方团队明确表示："本次辩论的首要目标是讨论新闻的真实性"，并提出关键点作为支持其立场的证据。反方也采取了类似的方法，提出了自己的论断。在提问和反驳阶段，双方都对对方的观点提出质疑，并对提出的问题做出回应。在总结陈词阶段，正方回顾并总结了之前的辩论，对反方的论点提出了质疑，并强化了自己的观点。反方虽然重申了自己的立场，但并没有对正方的观点提出深刻的质疑。最终，根据辩论的细节、语气和风格等因素，评委们决定支持正方。整个辩论过程形成了一个 "DebateFlow"，清晰地展示了评判过程。评委的辩论报告也可作为判断新闻是否为假新闻的依据，从而实现可解释的假新闻检测。这种可解释性对于现实生活中的编队验证至关重要，是 TED 框架的一大优势，也是其他模型难以实现的方面。

6 结论

总之，我们的研究介绍并评估了 TED 框架，这是一种新颖的假新闻检测方法，它将 LLM 的优势融入了结构化多代理辩论中。通过在 ARG-EN 和 ARG-CN 数据集上进行广泛的实验验证，TED 在多个性能指标上始终优于传统的机器学习和独立的 LLM。受人类辩论的启发，该框架的设计利用了双视角和结构化论证，为评估新闻条目的真实性提供了一种有效的机制。我们的工作不仅通过提高准确性和可解释性推动了假新闻检测领域的发展，还为开发负责任的信息系统提供了宝贵的见解。通过实现更可靠、更透明的内容评估，TED 有助于创建信息检索系统，更好地支持用户浏览和评估日益复杂的数字信息。

附录

在使用 ARG-CN 数据集的实验中，我们使用的提示是上述提示集的相应中文版本。所有其他函数都可以在我们的代码文件中找到，网址是：https://github.com/LiuYuHan31/TED_fake-news-detction。

致谢

本研究得到北京市杰出青年科学基金（BJJWZYJH012019100020098）和中国人民大学 "双一流 "建设重大创新规划平台--智慧社会治理平台的资助。刘宇涵受中国人民大学 "求是学术栋梁 "项目（编号：RUC24QSDL015）资助。

参考资料

[1] 约翰-波伦、毛慧娜、曾晓军。2011.推特情绪预测股市。计算科学杂志2，1（2011），1-8。[2] Robert James Branham。2013.辩论与批判性分析：冲突的和谐。Routledge.[3] 陈志敏、陈伟泽、苏玉生、于建轩、薛伟、张尚航、傅杰、刘志远。2024.ChatEval: Towards Better LLM-based Evaluators through Multi-Agent Debate.第十二届学习表征国际会议。[4] Justin Chih-Yao Chen, Swarnadeep Saha, and Mohit Bansal.2023.调和：arXiv preprint arXiv:2309.13007 (2023).[5] Xiuying Chen, Mingzhe Li, Shen Gao, Xin Cheng, Qiang Yang, Qishen Zhang, Xin Gao, and Xiangliang Zhang.2023.具有不同模态侧信息的主题感知摘要框架.SIGIR (2023).[6] Xiuying Chen, Guodong Long, Chongyang Tao, Mingzhe Li, Xin Gao, Chengqi Zhang, and Xiangliang Zhang.2023.用双重增强提高语法总结系统的鲁棒性》。ACL (2023).[7] Jacob Devlin、Ming-Wei Chang、Kenton Lee和Kristina Toutanova。2019.BERT：用于语言理解的深度双向变换器预训练。In Proceedings of the

2019 10 18653 1 19 1423

[8] 2003

Conference of the North. doi: ./v /n - Marko Djuranovic..The Ultimate Lincoln-Douglas Debate Handbook.2008年9月16日（2003年）检索。[9] Yilun Du, Shuang Li, Antonio Torralba, Joshua B Tenenbaum, and Igor Mordatch.2023.通过多代理辩论提高语言模型的事实性和推理能力。arXiv 预印本 arXiv:2305.14325 (2023).[10] Abhimanyu Dubey 、 Abhinav Jauhri 、 Abhinav Pandey、Abhishek Kadian、Ahmad Al-Dahle、Aiesha Letman、Akhil Mathur、Alan Schelten、Amy Yang、Angela Fan 等。骆驼 3 模型群。arXiv 预印本 arXiv:2407.21783 (2024).[11] Nir Grinberg, Kenneth Joseph, Lisa Friedland, Briony Swire-Thompson, and David Lazer.2019.2016年美国总统大选期间推特上的假新闻。科学》363，6425（2019），374-378。[12] Mingfei Guo, Xiuying Chen, Juntao Li, Dongyan Zhao, and Rui Yan.2021.假新闻进化的实证研究》。2021 年网络会议论文集》。407-411.[13] Aditi Gupta、Hemank Lamba、Ponnurangam Kumaraguru 和 Anupam Joshi。2013.伪造飓风 "桑迪"：飓风 "桑迪 "期间 Twitter 上虚假图片的特征描述与识别。第 22 届万维网国际会议论文集》。729-736.[14] Sirui Hong, Xiawu Zheng, Jonathan Chen, Yuheng Cheng, Jinlin Wang, Ceyao Zhang, Zili Wang, Steven Ka Shing Yau, Zijuan Lin, Liyang Zhou, et al.Metagpt：ArXiv preprint arXiv:2308.00352 (2023).[15] Beizhe Hu, Qiang Sheng, Juan Cao, Yuhui S hi, Yang Li, Danding Wang, and Peng Qi.2024.坏演员，好顾问：探索大语言模型在假新闻检测中的作用。In Proceedings of the AAAI Conference on Artificial Intelligence, Vol.22105-22113.[16] Beizhe Hu, Qiang Sheng, Juan Cao, Yongchun Zhu, Danding Wang, Zhengjia Wang, and Zhiwei Ji n.2023.学习过去，进化未来：ArXiv preprint arXiv:2306.14728 (2023).[17] Yiqiao Jin, Xiting Wang, Ruichao Yang, Yizhou Sun, Wei Wang, Hao Liao, and Xing Xie.2022.实现假新闻检测的细粒度推理。In Proceedings of the AAAI Conference on Artificial Intelligence, Vol. 36.5746-5754.[18] 赵开亚、米开朗基罗-纳伊姆、约瓦娜-孔迪奇、曼努埃尔-科尔特斯、葛佳欣、罗书英、杨光宇和安德鲁-安。2023.Lyfe Agents：用于低成本实时社交互动的生成式代理。ArXiv 预印本 arXiv:2310.02172 (2023).[19] Rohit Kumar Kaliyar, Anurag Goswami, and Pratik Narang.2021.FakeBERT：使用基于 BERT 的深度学习方法检测社交媒体中的假新闻。多媒体工具与应用80，8（2021），11765-11788。[20] Jackie Kazil, David Masad, and Andrew Crooks.2020.利用 python 进行基于代理的建模：mesa 框架。在社会、文化和行为建模中：第 13 届国际会议，SBP-BRiMS 2020，美国华盛顿特区，2020 年 10 月 18-21 日，论文集 13。Springer, 308-317.[21] Akbir Khan, John Hughes, Dan Valentine, Laura Ruis, Kshitij Sachan, Ansh Radhakrishnan, Edward Grefenstette, Samuel R Bowman, Tim Rocktäschel, and Ethan Perez.2024.与更有说服力的法学硕士辩论会得到更真实的答案》（Debating with More Persuasive LLMs Leads to More Truthful Answers.第四十一届机器学习国际会议。[22] Diederik P Kingma和Jimmy Ba.2014.arXiv预印本arXiv:1412.6980（2014）。[23] Chao Li, Xing Su, Chao Fan, Haoying Han, Cong Xue, and Chunmo Zheng.2023.量化大型语言模型对集体舆论动态的影响。arXiv预印本arXiv:2308.03313（2023）.[24] 李国豪、哈桑-哈穆德、哈尼-伊塔尼、德米特里-基兹布林和伯纳德-加内姆。2023.骆驼：探索大型语言模型社会的 "心智 "交流代理。神经信息处理系统进展 36 (2023)，51991-52008。[25] 李欣怡、张永峰和 Edward C Malthouse。2024.用于假新闻检测的大型语言模型代理。arXiv preprint arXiv:2405.01593 (2024).[26] Tian Liang, Zhiwei He, Wenxiang Jiao, Xing Wang, Yan Wang, Rui Wang, Yujiu Yang, Shuming Shi, and Zhaopeng Tu.2023.通过多代理辩论鼓励大型语言模型中的发散思维》。arXiv preprint arXiv:2305.19118 (2023).[27] Yuhan Liu, Xiuying Chen, Xiaoqing Zhang, Xing Gao, Ji Zhang, and Rui Yan.2024.从怀疑到接受：模拟对假新闻的态度动态。第三十三届国际人工智能联合会议论文集》。7886-7894.[28] Yuhan Liu, Zirui Song, Xiaoqing Zhang, Xiuying Chen, and Rui Yan.2024.从微小失误到巨大飞跃：ArXiv preprint arXiv:2410.19064 (2024).[29] Yuxuan Liu, Hongda Sun, Wenya Guo, Xinyan Xiao, Cunli Mao, Zhengtao Yu, and Rui Yan.2025.Bidev：用于复杂声明事实检查的双边化解验证。In Proceedings of the AAAI Conference on Artificial Intelligence, Vol.541-549.[30] Yuxuan Liu, Hongda Sun, Wei Liu, Jian Luan, Bo Du, and Rui Yan.2025.Mo- bileSteward：整合多个面向应用程序的代理与自我进化，自动执行跨应用程序指令。In Proceedings of the 31st ACM SIGKDD Conference on Knowledge Discovery and Data Mining V.1 (Toronto ON, Canada) (KDD '25).doi:10.1145/3690624.3709171[31] Ahmadreza Mosallanezhad, Mansooreh Karami, Kai Shu, Michelle V Mancenido, and Huan Liu.2022.通过强化学习进行领域自适应假新闻检测。2022 年 ACM 网络会议论文集》。3632-3640.[32] Qiong Nan, Juan Cao, Yongchun Zhu, Yanyan Wang, and Jintao Li.2021.MD- FEND：多域假新闻检测。第 30 届 ACM 国家间信息与知识管理大会论文集》。3343-3347.[33] Joon Sung Park、Joseph O'Brien、Carrie Jun Cai、Meredith Ringel Morris、Percy Liang和Michael S Bernstein。2023.生成代理：人类行为的交互式模拟。第 36 届 ACM 用户界面软件与技术研讨会论文集》。1-22.[34] Joon Sung Park、Lindsay Popowski、Carrie Cai、Meredith Ringel Morris、Percy Liang和Michael S Bernstein。2022.社会模拟：为社会计算系统创建填充原型。第 35 届 ACM 用户界面软件与技术研讨会论文集》。1-18.[35] Chen Qian, Xin Cong, Cheng Yang, Weize Chen, Yusheng Su, Juyuan Xu, Zhiyuan Liu, and Maosong Sun.2023.用于软件开发的通信代理。arXiv预印本arXiv:2307.07924 6 (2023).[36] Feng Qian, Chenggyue Gong, Karishma Sharma, and Yan Liu.2018.神经用户响应生成器：利用集体用户智能检测虚假新闻》。In IJCAI, Vol.3834-3840.[37] Yoel Roth.2022.我们对错误信息采取行动的绝大多数内容都是主动识别的。[38] Kai Shu、Deepak Mahudeswaran、Suhang Wang、Dongwon Lee 和 Huan Liu。2020.Fakenewsnet：一个包含新闻内容、社会背景和时空信息的数据存储库，用于研究社交媒体上的假新闻。大数据8，3 2020 171 188 ( ), - .[39] 宋子瑞、李耀航、方萌、陈振豪、施泽成、黄源。2024.Mmac-copilot：ArXiv e-prints (2024), arXiv-2404.[40] Kate Starbird, Jim Maddock, Mania Orand, Peg Achterman, and Robert M Mason.2014.谣言、虚假旗帜和数字守夜人：2013年波士顿马拉松爆炸案后微博上的错误信息》。IConference 2014 proceedings (2014).[41] Yashar Talebirad and Amirhossein Nadiri.2023.多代理协作：ArXiv preprint arXiv:2306.03314 (2023).[42] Petter Törnberg, Diliara Valeeva, Justus Uitermark, and Christopher Bail.2023.使用大型语言模型模拟社交媒体以评估替代新闻源算法。arXiv preprint arXiv:2310.05984 (2023).[43] Petar Veličković、Guillem Cucurull、Arantxa Casanova、Adriana Romero、Pietro Liò和Yoshua Bengio。2018.图注意网络。In International Con- ference on Learning Representations.[44] Yaqing Wang, Fenglong Ma, Zhiwei Jin, Ye Yuan, Guangxu Xun, Kishlay Jha, Lu Su, and Jing Gao.2018.Eann：用于多模态假新闻检测的事件对抗神经网络。第 24 届 ACM SIGKDD 知识发现与数据挖掘国际会议论文集》。849-857.[45] Biao Wu, Yanda Li, Meng Fang, Zirui Song, Zhiwei Zhang, Yunchao Wei, and Ling Chen.2024.多模态移动代理的基础与最新趋势：ArXiv preprint arXiv:2411.02006 (2024).[46] Qingyun Wu, Gagan Bansal, Jieyu Zhang, Yiran Wu, Shaokun Zhang, Erkang Zhu, Beibin Li, Li Jiang, Xiaoyun Zhang, and Chi Wang.2023.Autogen：ArXiv preprint arXiv:2308.08155 (2023).[47] Canwen Xu, Yichong Xu, Shuohang Wang, Yang Liu, Chenguang Zhu, and Julian McAuley.2023.小型模型是大型语言模型的宝贵插件. arXiv preprint arXiv:2305.08848 (2023).

[48] 杨安、杨宝松、张北辰、惠斌元、郑波、于博文、李成元、刘大义恒、黄飞、魏浩然等 2024.Qwen2.5技术报告。arXiv预印本arXiv:2412.15115（2024）。[49] Feng Yu, Qiang Liu, Shu Wu, Liang Wang, Tieniu Tan, et al.错误信息识别的卷积方法。In IJCAI.3901-3907.[50] 刘宇涵、陈秀英、闫睿。2023.释放大型模型的力量：探索人机对话。第22届全国计算语言学大会论文集（第二卷：前沿论坛）》。16-29.[51] 张俊田、程传启、刘宇涵、刘伟、栾健、闫睿。2025.跨图像编织语境：ArXiv preprint arXiv:2504.20199 (2025).[52] Jintian Zhang, Xin Xu, Ningyu Zhang, Ruibo Liu, Bryan Hooi, and Shumin Deng.2024.探索 LLM 代理的协作机制：社会心理学视角。In ICLR 2024 Workshop on Large Language Model (LLM) Agents.[53] Xueyao Zhang, Juan Cao, Xirong Li, Qiang Sheng, Lei Zhong, and Kai Shu.2021.为假新闻检测挖掘双重情感。2021年网络会议论文集》。3465-3476.[54] Xiaoqing Zhang, Xiuying Chen, Yuhan Liu, Jianzhou Wang, Zhenxing Hu, and Rui Yan.2024.数字广告活动中影响者选择的大规模时间感知代理模拟。arXiv预印本arXiv:2411.01143（2024）。2024.SAGraph：大规模文本丰富的社交图谱数据集

arXiv preprint arXiv:2403.15105 (2024).[56] 张小青、刘宇涵、宋洪水、陈秀英、闫蕊。2024.运行前思考！高效代码生成与彻底探索和优化细化。arXiv preprint arXiv:2502.17442 (2024).[57] Zheng Zhang, Qi Liu, Zirui Hu, Yi Zhan, Zhenya Huang, Weibo Gao, and Qingyang Mao.2024.通过自适应采样增强元学习用户建模的公平性。2024 年 ACM 网络会议论文集》。3241-3252.[58] 张正、刘琦、蒋浩、王飞、庄艳、吴乐、高伟波和陈恩洪。2023.FairLISA：有限敏感属性信息下的公平用户建模。第 37 届神经信息处理系统国际会议论文集》。41432-41450.[59] 张正、宋伟、刘琦、毛庆阳、王一燕、高伟波、黄振亚、王世金、陈恩洪。 [n.d.]。通过单调数据增强实现准确公平的认知诊断。在第三十八届神经信息处理系统年会上。[60] 郑家琪，张曦，郭三川，王泉，臧文宇和张永东。2022.MFAN：用于谣言检测的多模态特征增强注意力网络。IJCAI.[61] Yongchun Zhu, Qiang Sheng, Juan Cao, Shuokai Li, Danding Wang, and Fuzhen Zhuang.2022.泛化未来：减轻假新闻检测中的实体偏差。第 45 届 ACM SIGIR 信息检索研究与发展国际会议论文集》。2120-2125.